

MNIST 분류기의 Bound-Propagation 강건성 검증: α, β -CROWN과 Marabou 비교

백재민

초록

소형 완전연결 MNIST 분류기의 국소 ℓ_∞ 강건성을 α, β -CROWN로 검증하고, 동일한 인스턴스에서 이전에 사용한 SMT 기반 검증기 Marabou와 비교한다. 두 도구는 공유된 모든 판정과 샘플별 강건성 임계값에서 일치했으며, 이를 건전성 (soundness) 교차검증으로 활용한다. 흥미로운 차이는 정량적이다: 속도 격차는 상수가 아니라 특정 ε 에서 벌어지고, 검증 노력은 좁은 ε 구간에서 값싼 bound로부터 branch-and-bound로 옮겨가며, 모든 반례는 탐색이 아니라 공격으로 발견되고, 어려운 인스턴스의 성패는 솔버가 아니라 분기 휴리스틱 선택이 좌우한다.

1 설정

모델과 데이터. 네트워크는 ReLU 활성화 (은닉 96개)를 갖는 완전연결 분류기 $784 \rightarrow 64 \rightarrow 32 \rightarrow 10$ 이며, ONNX로 내보내 Marabou 연구에서 그대로 재사용했다. 두 도구가 동일한 네트워크를 동일한 입력에서 검증하도록 하기 위함이다. 입력은 MNIST 테스트 이미지로, 평균 0.1307, 표준편차 0.3081로 정규화되어 값이 $[-0.4242, 2.8215]$ 에 놓인다.

속성. 입력 x (정답 L)와 반경 ε 에 대해 국소 ℓ_∞ 강건성을 검증한다: $\|x' - x\|_\infty \leq \varepsilon$ (유효 범위로 clip)인 모든 x' 에서 네트워크가 L 를 arg-max로 유지하는가. Marabou 질의와 정확히 맞추기 위해 섭동을 정규화 공간에 적용한 per-instance VNNLIB로 인코딩한다(UNSAT $\Rightarrow$ 검증됨, SAT $\Rightarrow$ 반증됨). α, β -CROWN는 CPU에서 branch-and-bound(Gurobi 미사용), kfsb 분기 휴리스틱으로 실행한다.

2 결과 및 해석

Phase 1 — 스캔 (100 샘플, $\varepsilon = 0.05$). 96개 강건 검증, 4개 반증 (샘플 8, 33, 92, 96), timeout 0; 인스턴스당 평균 0.21 초.

Phase 2 — 임계값. 반증되는 최소 ε 는 샘플 8이 0.03, 샘플 33이 0.05이며, 샘플 0은 $\varepsilon = 0.20$ 까지 강건하다. 이는 Marabou 임계값과 정확히 일치한다.

속도 우위는 상수가 아니라 ε 에 의존한다. 강건 샘플 0에서 작은 반경일 때 두 도구는 사실상 동등이고 ($\varepsilon = 0.01$: Marabou 0.39 초, α, β -CROWN 0.30 초), $\varepsilon = 0.11$ 까지 비등하다 (Marabou 1.0 초). 이후 Marabou는 급격히 악화되어 $\varepsilon = 0.12$ 에서 6.2 초, $\varepsilon \geq 0.19$ 에서 300 초 timeout에 이르는 반면, α, β -CROWN는 $\varepsilon = 0.20$ 에서도 1.5 초에 그친다(그림 1a). 흔히 인용되는 $\sim 270\times$ 격차는 꼬리의 성질이며, 정직한 요약은 “ $\varepsilon \approx 0.11$ 까지 대등, 이후 SMT 탐색이 급락”이다.

노력이 어디로 가는가, 그리고 급격한 전이. 100개 인스턴스가 각각 어떻게 해결되는지를 분해하면 (그림 1b), 값싼 incomplete CROWN bound가 $\varepsilon \leq 0.02$ 에서는 100개 모두를, 그러나 $\varepsilon = 0.20$ 에서는 단 5개만 해결한다. branch-and-bound 비증은 $\varepsilon \approx 0.12$ –0.15의 좁은 구간에서 가파르게 상승한다. 검증 난이도는 ε 전반에 고르게 퍼진 것이 아니라 한 구간에 집중되어 있다.

모든 반례는 탐색이 아니라 공격에서 나온다. 모든 ε 에서 반증 인스턴스는 PGD 공격 (unsafe-pgd)으로 해결되며 branch-and-bound로는 결코 해결되지 않는다 (unsafe-bab = 0). 이 네트워크에서는 값싼 공격만으로도 반증이 충분하며, 비싼 완전 탐색은 거의 전적으로 강건성을 증명하는 데 쓰인다. 복원된 반례는 뚜렷한 오분류이다 (예: 샘플 8: $5 \rightarrow 6$; 33: $4 \rightarrow 0$; 92: $9 \rightarrow 4$; 96: $1 \rightarrow 9$), 각각 ε -공 안의 작은 섭동이다(그림 2).




Figure 1: (a) 강건 샘플 0의 ϵ 대비 검증 시간(로그 축): $\epsilon \approx 0.11$ 까지 비등, 이후 Marabou는 timeout, α, β -CROWN는 약 1.5초 유지. (b) ϵ 증가에 따른 100개 인스턴스의 해결 방식; branch-and-bound 비중이 $\epsilon \approx 0.12$ –0.15에서 급증.




Figure 2: $\epsilon = 0.05$ 에서 샘플 8의 반례(원본 | 적대적 | 섭동): ℓ_∞ 섭동이 예측을 5→6으로 뒤집는다.

3 Marabou와의 비교

	α, β -CROWN	Marabou
방법	선형 완화 + branch-and-bound	SMT (Reluplex)
인터페이스	선언형 YAML + VNNLIB	명령형 Python API
공유 인스턴스 판정	동일	동일
강건 샘플, $\epsilon = 0.20$	~1.5초	300초 (timeout)
단일 소형 쿼리(콜드 스타트)	~2.5초	~0.5초

표 이외에 실험에서 얻은 세 가지를 짚는다. 첫째, 일치 자체가 결과다: 도구 간 속성을 맞추려면 VNNLIB 안에서 ϵ 를 정규화 공간에 적용해야 했고, 동일한 임계값(0.03, 0.05)은 인코딩이 정확함과 두 독립 엔진이 상호 일관됨을 모두 확인해 준다. 둘째, “사용 편의성”은 양면적 이었다: α, β -CROWN의 config 기반 배치 모드는 100샘플 스왑을 한 번의 실행으로 만들었지만, 동작하는 환경에 이르기까지 도구 특유의 마찰(Gurobi를 쓰지 않아도 강제되는 `gurobipy import`, CPU 전용 빌드)을 처리해야 했다. 반면 Marabou의 Python API는 일회성 쿼리에 더 직접적이다. 셋째, 복원된 반례는 일치할 필요가 없다: Marabou의 비엄격 위반 인코딩 ($\text{output}[j] \geq \text{output}[L]$)은 arg-max가 정답과 동점인 점을 반환할 수 있는 반면, α, β -CROWN의 PGD는 엄격한 오분류를 반환한다 — 둘 다 동일한 비강건성의 유효한 증거다.

4 강점과 한계

강점. α, β -CROWN는 SMT가 하지 못하는 방식으로 우아하게 확장된다: 100개 테스트 샘플 전부를 값싸게 인증했고(따라서 강건성 반경 분포 전체를 도출 — 43/100이 $\epsilon = 0.20$ 을 넘어서도 강건), Marabou를 timeout으로 몰아넣은 큰 ϵ 의 강건 사례들을 해결했다.

관찰된 한계. (i) 항상 빠른 것은 아니다: 단일 소형 쿼리는 콜드 스타트 시 ~2.5초로 Marabou의 ~0.5초보다 느린데, 소형 모델에서는 프로세스 시작 비용이 지배하기 때문이다. 이점은 시작 비용이 배치 전반에 amortize될 때 비로소 나타난다. (ii) 성패가 솔버가 아니라 분기 휴리스틱에 달릴 수 있다: 가장 어려운 인스턴스(샘플 22, $\epsilon = 0.2$)에서 kfsb는 31초에 검증했으나 fsb는 timeout, babsr는 upstream AttributeError로 크래시했다. 기본값 kfsb는 동작했지만, 설정 표면이 넓고 균일하게 견고하지는 않음을 보여준다.